Лабораторна робота №1
Частина 2

CNN для класифікації зображень
Мета роботи

Метою даної частини лабораторної роботи є набуття глибоких теоретичних знань та практичних навичок у розробці, навчанні та оцінці згорткової нейронної мережі (CNN) для задачі бінарної класифікації медичних зображень. У рамках роботи буде розроблено та застосовано модель для автоматизованого виявлення пневмонії на рентгенівських знімках грудної клітки. Ключовими завданнями є аналіз результатів, оцінка продуктивності моделі за допомогою відповідних метрик та інтерпретація її поведінки, включаючи аналіз помилок.

Теоретичний матеріал

Вступ до Згорткових Нейронних Мереж (CNN)

Згорткові нейронні мережі (Convolutional Neural Networks, CNN або ConvNet) є класом архітектур глибокого навчання, що здійснили революцію в галузі комп'ютерного зору. На відміну від традиційних підходів, які покладалися на ручну розробку ознак (feature engineering), CNN здатні автоматично вивчати ієрархію ознак безпосередньо з необроблених даних, таких як пікселі зображення. Ця здатність до автоматичного навчання ознак є ключовою перевагою, що дозволяє досягати надзвичайної ефективності в задачах розпізнавання об'єктів, сегментації та класифікації зображень.

Історично, концепція CNN бере свій початок від піонерської роботи Яна ЛеКуна та його колег, які у 1998 році представили архітектуру LeNet-5 для розпізнавання рукописних цифр. Однак справжній прорив відбувся у 2012 році, коли архітектура AlexNet, розроблена Алексом Крижевським та іншими, продемонструвала безпрецедентну продуктивність на масштабному датасеті ImageNet, значно перевершивши всі існуючі на той час методи. Цей успіх каталізував сучасну еру глибокого навчання та широке впровадження CNN у різноманітних прикладних задачах.

Архітектура CNN частково натхненна біологічними процесами, що відбуваються в зоровій корі головного мозку. Подібно до того, як нейрони в мозку реагують на стимули в обмежених ділянках поля зору (рецептивних полях), нейрони в CNN обробляють інформацію лише в невеликих локальних областях вхідного зображення. Ця ієрархічна структура дозволяє мережі спочатку виявляти прості ознаки, такі як краї та кути, а потім, на глибших шарах, комбінувати їх для розпізнавання складніших об'єктів, таких як очі, обличчя або, у нашому випадку, патологічні зміни в легенях.

Ключові Архітектурні Елементи CNN

CNN складається з послідовності шарів, кожен з яких виконує певну функцію. Основними будівельними блоками є згорткові шари, шари підвибірки та повнозв'язні шари.

Згортковий Шар (Convolutional Layer) Це основний компонент CNN, де відбувається вилучення ознак. Його робота базується на операції згортки — покомпонентному добутку між невеликою матрицею вагових коефіцієнтів, що називається фільтром або ядром, та відповідною ділянкою вхідного зображення. Фільтри навчаються виявляти специфічні локальні патерни, такі як вертикальні або горизонтальні лінії, градієнти, текстури тощо. Результатом застосування одного фільтра до всього зображення є карта ознак (feature map), яка показує, в яких областях зображення була виявлена ознака, на яку "налаштований" фільтр. Поведінка згорткового шару контролюється кількома гіперпараметрами:

1. Крок (Stride): Визначає, на скільки пікселів фільтр зсувається по зображенню на кожному кроці.
2. Доповнення (Padding): Додавання нулів по краях зображення, що дозволяє контролювати просторовий розмір вихідної карти ознак і обробляти інформацію на межах зображення.

Ключовою властивістю CNN є **спільне використання ваг (Shared Weights)**. Це означає, що один і той самий фільтр (з однаковими вагами) застосовується до всіх ділянок зображення. Такий підхід значно зменшує кількість параметрів, що навчаються, у порівнянні з повнозв'язними мережами, і робить модель інваріантною до зсуву об'єктів на зображенні.

Функція активації (Activation Function), після кожного згорткового шару застосовується нелінійна функція активації. Її роль полягає у введенні нелінійності в модель, що дозволяє мережі вивчати складні, нелінійні залежності в даних. Без нелінійності вся нейронна мережа, незалежно від її глибини, була б еквівалентною одному лінійному перетворенню. Найпоширенішою функцією активації в сучасних CNN є ReLU (Rectified Linear Unit), що визначається формулою $f(x)=\max(0,x)$. Вона обчислювально ефективна і допомагає уникнути проблеми зникаючого градієнта, що прискорює навчання.

Шар підвибірки (Pooling Layer) - зазвичай слідує за згортковим шаром і виконує функцію зменшення просторової розмірності карт ознак. Це робить модель обчислювально ефективнішою, зменшує кількість параметрів і створює невелику інваріантність до локальних зсувів та деформацій об'єктів. Найпопулярнішим типом є Max Pooling, де з кожної ділянки карти ознак (наприклад, 2x2) обирається максимальне значення.

Повнозв'язний шар (Fully Connected Layer), після серії згорткових та пулінгових шарів, які діють як ієрархічний екстрактор ознак, отримані карти ознак "випрямляються" (flatten) у одновимірний вектор. Цей вектор подається на один або кілька повнозв'язних шарів, які виконують фінальну класифікацію на основі вивчених високо-рівневих ознак. Останній повнозв'язний шар зазвичай має кількість нейронів, що дорівнює кількості класів у задачі.

Функція втрат та оптимізація для задачі бінарної класифікації (наприклад, "Пневмонія" проти "Норма") як функція втрат зазвичай використовується бінарна перехресна ентропія (Binary Cross-Entropy). Вона вимірює розбіжність між прогнозованими ймовірностями та справжніми мітками. Для оновлення ваг мережі з метою мінімізації функції втрат застосовуються оптимізаційні алгоритми, серед яких

Adam є одним з найпопулярніших завдяки своїй ефективності та адаптивній швидкості навчання.

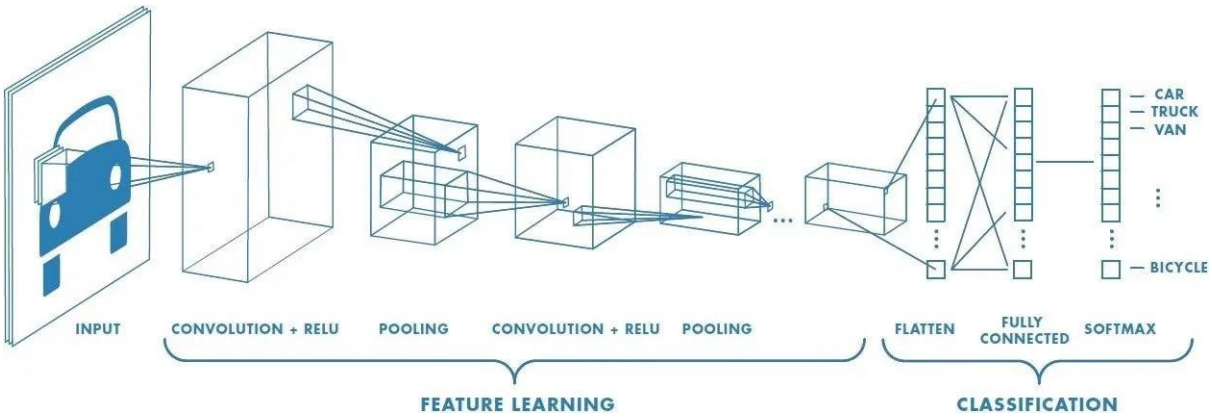


Рис. 1. Архітектура розпізнавання образів у CNN мережі.

Практична Реалізація: Розпізнавання Пневмонії на Рентгенівських Знімках

Для вирішення поставленої задачі використовується публічний датасет "Chest X-Ray Images (Pneumonia)" з платформи Kaggle. Цей набір даних містить 5,863 рентгенівських знімки грудної клітки дітей віком від одного до п'яти років, які були відібрані з ретроспективних когорт у Медичному центрі для жінок та дітей Гуанчжоу. Зображення розмічені на два класи: "NORMAL" (здорові легені) та "PNEUMONIA" (наявність пневмонії)

Датасет організований у стандартну для задач комп'ютерного зору структуру каталогів: ***train, test*** та ***val***, кожен з яких містить підкаталоги ***NORMAL*** та ***PNEUMONIA***. Такий поділ дозволяє належним чином навчати, валідувати та тестувати модель.

При первинному аналізі даних виявляється значний дисбаланс класів: кількість знімків з діагнозом "PNEUMONIA" суттєво перевищує кількість знімків "NORMAL". Наприклад, у навчальному наборі може бути близько 3800 знімків пневмонії проти 1300 нормальних. Цей дисбаланс має важливі наслідки. Якщо модель навчати на таких даних без жодної корекції, вона може розвинути сильну упередженість до прогнозування мажоритарного класу. В результаті, стандартна метрика точності (***accuracy***) може бути оманливо високою, оскільки модель буде правильно класифікувати більшість зразків, просто ігноруючи міноритарний клас. Тому для адекватної оцінки продуктивності необхідно використовувати метрики, чутливі до дисбалансу, такі як ***precision, recall*** та ***F1-score***, а також детально аналізувати матрицю помилок.

Першим кроком є налаштування робочого середовища та завантаження даних. Ми будемо використовувати бібліотеку TensorFlow з її високорівневим API Keras.

```
import tensorflow as tf
import keras
from keras import layers
import matplotlib.pyplot as plt
```

```python
import numpy as np
import os
import kagglehub

IMAGE_SIZE = 180
BATCH_SIZE = 32
EPOCHS = 25

base_dir = kagglehub.dataset_download("paultimothymooney/chest-xray-pneumonia")
train_dir = os.path.join(base_dir, 'chest_xray/train')
val_dir = os.path.join(base_dir, 'chest_xray/val')
test_dir = os.path.join(base_dir, 'chest_xray/test')

# Завантаження даних за допомогою утиліти Keras
# Ця функція автоматично створює мітки на основі структури каталогів
train_ds = tf.keras.utils.image_dataset_from_directory(
    train_dir,
    labels='inferred',
    label_mode='binary',
    image_size=(IMAGE_SIZE, IMAGE_SIZE),
    batch_size=BATCH_SIZE,
    shuffle=True,
    seed=123
)

val_ds = tf.keras.utils.image_dataset_from_directory(
    val_dir,
    labels='inferred',
    label_mode='binary',
    image_size=(IMAGE_SIZE, IMAGE_SIZE),
    batch_size=BATCH_SIZE,
    shuffle=False
)

test_ds = tf.keras.utils.image_dataset_from_directory(
    test_dir,
    labels='inferred',
    label_mode='binary',
    image_size=(IMAGE_SIZE, IMAGE_SIZE),
    batch_size=BATCH_SIZE,
    shuffle=True
)

# Виведемо назви класів (0 -> NORMAL, 1 -> PNEUMONIA)
class_names = train_ds.class_names
print("Класи:", class_names)

# Візуалізуємо кілька прикладів зображень
plt.figure(figsize=(10, 10))
for images, labels in test_ds.take(1):
    for i in range(9):
```

```
        ax = plt.subplot(3, 3, i + 1)
        plt.imshow(images[i].numpy().astype("uint8"))
        plt.title(class_names[int(labels[i])])
        plt.axis("off")
plt.show()

# Нормалізація даних
# Створюємо шар для масштабування значень пікселів з  до
rescale_layer = layers.Rescaling(1./255)
train_ds = train_ds.map(lambda x, y: (rescale_layer(x), y))
val_ds = val_ds.map(lambda x, y: (rescale_layer(x), y))
test_ds = test_ds.map(lambda x, y: (rescale_layer(x), y))

# Оптимізація продуктивності завантаження даних
AUTOTUNE = tf.data.AUTOTUNE
train_ds = train_ds.cache().prefetch(buffer_size=AUTOTUNE)
val_ds = val_ds.cache().prefetch(buffer_size=AUTOTUNE)
test_ds = test_ds.cache().prefetch(buffer_size=AUTOTUNE)
```

При роботі з медичними зображеннями, такими як рентгенівські знімки, важливо обережно підходити до аугментації даних. Хоча аугментація є потужним інструментом для покращення узагальнюючої здатності моделі, деякі перетворення можуть бути недоречними. Рентгенівські знімки зазвичай робляться у стандартизованих положеннях, тому сильні геометричні перетворення, як-от вертикальне віддзеркалення (***vertical_flip***) або значні обертання, можуть створити нереалістичні зразки, які ніколи не зустрінуться в клінічній практиці. Це може ввести в модель артефакти, що суперечать медичній реальності, і потенційно погіршити її продуктивність на реальних даних. Тому в даній роботі ми утримуємося від агресивної аугментації.

Тепер створимо просту, але ефективну архітектуру CNN за допомогою ***tf.keras.Sequential***. Модель складатиметься з трьох згорткових блоків, кожен з яких містить ***Conv2D*** та ***MaxPooling2D*** шари. Після вилучення ознак дані випрямляються і подаються на повнозв'язні шари для класифікації.

```
# Створення послідовної моделі
model = keras.Sequential([

layers.Input(shape=(IMAGE_SIZE,
IMAGE_SIZE, 3)),

    layers.Conv2D(32, (3, 3),
activation='relu',
padding='same'),
    layers.MaxPooling2D((2,
2)),

    layers.Conv2D(64, (3, 3),
activation='relu',
padding='same'),
    layers.MaxPooling2D((2,
2)),

    layers.Conv2D(128, (3, 3),
activation='relu',
```

```
padding='same'),
    layers.MaxPooling2D((2,
2)),

    layers.Flatten(),
    layers.Dense(128,
activation='relu'),
    layers.Dropout(0.4),
    layers.Dense(1,
activation='sigmoid')
])

# Вивід архітектури моделі
model.summary()
```

Після визначення архітектури модель необхідно скомпілювати, вказавши оптимізатор, функцію втрат та метрики, а потім запустити процес навчання.

```
# Компіляція моделі
model.compile(
    optimizer='adam',
    loss='binary_crossentropy',
    metrics=[ 'accuracy',
    keras.metrics.Precision(name='precision'),
    keras.metrics.Recall(name='recall'),
    keras.metrics.AUC(name='auc') ]

)

early_stopping = keras.callbacks.EarlyStopping(
    monitor='val_loss',
    patience=5,
    restore_best_weights=True
)

history = model.fit(
    train_ds,
    validation_data=val_ds,
    epochs=EPOCHS,
    callbacks=[early_stopping]
)
```

Після завершення навчання моделі необхідно проаналізувати її продуктивність. Це включає аналіз динаміки навчання, оцінку на тестових даних та детальне вивчення помилок. Графіки точності та втрат на тренувальній та валідаційній вибірках дозволяють оцінити, як проходив процес навчання.

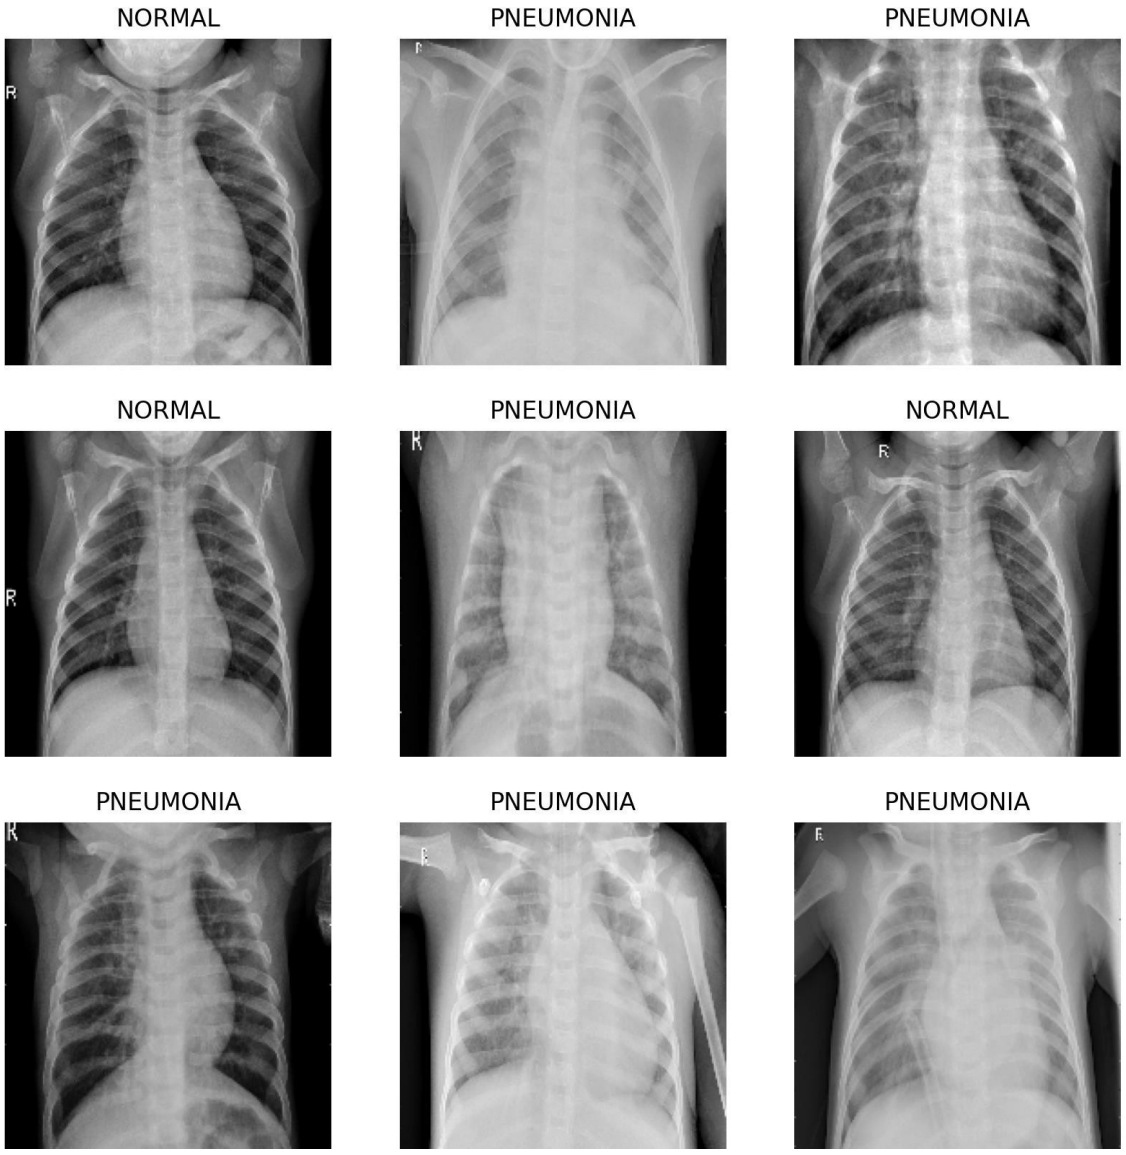


Рис. 2. Приклади рентгенівських зображень класів NORMAL та PNEUMONIA.

Індивідуальні завдання

Виконати класифікацію медичних зображень за допомогою CNN на відкритому датасеті.

1. Завантажити підмножину даних (напр., 500–1000 зображень), зробити опис полів та класів.

2. Підготувати дані: розділити на тренувальну та тестову вибірки, виконати аугментацію (повороти, зсуви), змінити розмір зображень, нормалізувати значення пікселів.
3. Навчити модель CNN з базовими гіперпараметрами.
4. Оцінити якість за потрібними метриками.
5. Побудувати візуалізації.
6. Зробити аналіз похибок (хибно-позитивні, хибно-негативні), висновки щодо ефективності моделі та пропозиції для покращення.
7. Висновки

Рекомендовані налаштування за замовчуванням:

- Архітектура: 3–4 згорткових блоки (Conv2D + MaxPooling2D), Flatten, 1–2 Dense шари, Dropout (0.3–0.5).
- Оптимізатор: Adam з `learning_rate=0.001`.
- Функція втрат: `binary_crossentropy` для 2 класів, `categorical_crossentropy` для 3+ класів.
- Навчання: `batch_size=32`, `epochs=20–50` з `EarlyStopping` (моніторинг `val_loss`).
- Метрики: `accuracy`, `precision`, `recall`, `f1-score`, `confusion matrix`.

№	Завдання	Метод	Тип даних	Результат	Датасет
1	Класифікація пухлин мозку (4 класи)	CNN (ResNet50)	МРТ знімки	Модель для мультикласової класифікації	Brain Tumor Classification (MRI) 1
2	Розпізнавання бактеріальної та вірусної пневмонії	CNN (VGG16)	Рентген грудної клітки	Модель для мультикласової класифікації (Normal, Bacteria, Virus)	Pneumonia Multi-Class 2
3	Виявлення COVID-19 на рентгенівських знімках	CNN (EfficientNet)	Рентген грудної клітки	Модель для класифікації (COVID-19, Normal, Pneumonia)	COVID-19 Radiography Database 3
4	Класифікація захворювань шкіри (7 класів)	CNN (InceptionV3)	Дерматоскопічні зображення	Мультикласовий класифікатор дерматологічних захворювань	HAM10000 "Skin Cancer MNIST" 4
5	Виявлення переломів кісток	CNN (Custom)	Рентген знімки	Бінарний класифікатор (перелом / немає перелому)	Bone Fracture Classification
6	Класифікація захворювань сітківки ока	CNN (DenseNet121)	Знімки сітківки (OCT)	Мультикласовий класифікатор (CNV, DME, Drusen, Normal)	Retinal OCT Images
7	Аналіз впливу аугментації на точність	CNN (Custom)	Рентген грудної клітки	Порівняльний аналіз точності з/без аугментації	Chest X-Ray Images (Pneumonia)
8	Порівняння оптимізаторів (Adam vs SGD vs RMSprop)	CNN (Custom)	МРТ знімки	Графіки збіжності та фінальні метрики для кожного оптимізатора	Brain Tumor MRI Dataset 5

9	Застосування трансферного навчання (feature extraction)	VGG19 (заморожена) + Dense	Рентген грудної клітки	Класифікатор пневмонії	Chest X-Ray Images (Pneumonia)
10	Застосування fine-tuning (тонке налаштування)	ResNet50 (частково розморожена)	МРТ знімки	Класифікатор пухлин мозку	Brain Tumor Classification (MRI) 1
11	Дослідження впливу Dropout та L2-регуляризації	CNN (Custom)	Рентген грудної клітки	Аналіз перенавчання та узагальнюючої здатності моделі	Chest X-Ray Images (Pneumonia)
12	Візуалізація "уваги" моделі за допомогою Grad-CAM	CNN (будь-яка)	Рентген знімки з пневмонією	Теплові карти, що показують області інтересу моделі	Chest X-Ray Images (Pneumonia)
13	Мультикласова класифікація захворювань легень	CNN (Xception)	Рентген грудної клітки	Класифікатор (Normal, Pneumonia, COVID-19, Tuberculosis)	Chest X-ray (6 classes) dataset 6
14	Оцінка моделі при дисбалансі класів	CNN (Custom)	Рентген грудної клітки	Аналіз Precision, Recall, F1-score, AUC-ROC	Chest X-Ray Images (Pneumonia)
15	Вплив розміру вхідного зображення на продуктивність	CNN (Custom)	МРТ знімки	Порівняння точності та часу навчання для розмірів 64x64, 128x128, 224x224	Brain Tumor MRI Dataset 5
16	Класифікація типів клітин крові (8 класів)	CNN (MobileNetV2)	Мікроскопічні зображення	Мультикласовий класифікатор клітин крові	Blood Cell Images
17	Виявлення туберкульозу	CNN (DenseNet201)	Рентген грудної клітки	Бінарний класифікатор (Tuberculosis / Normal)	Tuberculosis (TB) Chest X-ray Database
18	Застосування різних функцій активації (ReLU vs LeakyReLU)	CNN (Custom)	Рентген грудної клітки	Порівняльний аналіз динаміки навчання	Chest X-Ray Images (Pneumonia)
19	Розпізнавання раку шкіри (23 класи)	CNN (EfficientNetB3)	Дерматологічні зображення	Мультикласовий класифікатор раку шкіри	Dermnet Dataset 7
20	Побудова ансамблю з кількох CNN моделей	VGG16 + ResNet50	МРТ знімки	Підвищення точності класифікації пухлин шляхом усереднення прогнозів	Brain Tumor Classification (MRI) 1

Зміст звіту

Звіт з лабораторної роботи повинен містити:

1. Титульний аркуш із зазначенням назви лабораторної роботи, номера варіанта, прізвища студента та навчальної групи.
2. Індивідуальне завдання відповідно до номера варіанта із зазначенням обраного датасету, архітектури CNN та особливостей дослідження.
3. Короткий опис набору даних, що містить:

   - призначення та джерело датасету;
   - кількість зображень;
   - перелік класів;
   - розподіл зображень за класами;

- розмір і формат вхідних зображень;
- спосіб поділу даних на навчальну, валідаційну та тестову вибірки.

4. Опис попередньої обробки даних, зокрема:

   - зміна розміру зображень;
   - нормалізація значень пікселів;
   - застосовані способи аугментації та коротке обґрунтування їх вибору.

5. Програмний код реалізації CNN, що включає завантаження і підготовку даних, побудову, компіляцію, навчання та тестування моделі, а також виконання індивідуального завдання.
6. Структуру моделі CNN (`model.summary()`) та короткий опис її основних компонентів: згорткових шарів, шарів підвибірки, повнозв'язних шарів, функцій активації, Dropout та вихідного шару.
7. Параметри навчання моделі, зокрема:

   - оптимізатор і значення `learning_rate`;
   - функцію втрат;
   - `batch size`;
   - максимальну кількість епох;
   - використані механізми регуляризації та `EarlyStopping`, якщо вони застосовувалися.

8. Результати навчання моделі, що містять:

   - графік зміни функції втрат (`loss`) для навчальної та валідаційної вибірок;
   - графіки зміни основних метрик у процесі навчання;
   - короткий аналіз процесу навчання та наявності ознак перенавчання або недонавчання.

9. Результати тестування моделі, що містять значення основних метрик класифікації: `accuracy`, `precision`, `recall`, `F1-score` та, за потреби, `AUC-ROC`.
10. Матрицю помилок (confusion matrix) та її аналіз із визначенням кількості правильно і неправильно класифікованих об'єктів.
11. Аналіз помилок класифікації, що містить приклади хибнопозитивних (`False Positive`) і хибнонегативних (`False Negative`) прогнозів та можливі причини таких помилок.
12. Результати виконання індивідуального завдання із відповідними таблицями, графіками, зображеннями або порівнянням моделей/параметрів залежно від варіанта.
13. Аналіз отриманих результатів, у якому необхідно оцінити ефективність побудованої CNN, вплив досліджуваного в індивідуальному завданні фактора та запропонувати можливі способи покращення моделі.
14. Висновки, у яких стисло узагальнити результати виконання роботи, зазначити досягнуті показники якості, основні виявлені проблеми та можливі напрями покращення моделі.